

**LAPORAN
UJIAN AKHIR SEMESTER**



NIM : A11.2024.15549
NAMA : NA'ILAH AZFA ZARQARIDA
MATA KULIAH : PEMBELAJARAN MESIN

**PROGAM STUDI TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS DIAN NUSWANTORO SEMARANG
2026**

DAFTAR ISI

DAFTAR ISI	2
BAB I PENDAHULUAN & STUDI LITERATUR	4
1.1. Latar Belakang	4
1.2. Tujuan Proyek	4
1.3 Relevansi Dengan Outcome-Based Education (OBE)	5
1.4 Kajian Pustaka Prediksi Kelulusan Mahasiswa	5
1.5 Sesintesis Temuan Dan Metode Optimasi	5
BAB II DATASET DAN DATA DICTIONARY	6
2.1. Sumber Dataset	6
2.2. Fitur Yang Digunakan (Top 8 Berdasarkan Mutual Information)	7
2.3. Etika Pengguna Data	7
BAB III AUDIT DATA DAN PREPROCESSING	8
3.1. Hasil Audit Dataset	8
3.2. Encoding Dan Scaling	8
3.3. Encoding Dan Scaling	8
3.4. Leakage Awarness.....	8
BAB IV DESAIN EKSPERIMEN.....	9
4.1. Pembagian Data.....	9
4.2. Algoritma Klasifikasi	9
4.3. Parameter Baseline	9
4.4. Hyperparameter Grid Untuk Optimasi	9
4.5. Validasi Silang Dan Metrik Evaluasi	10
BAB V HASIL EKSPERIMEN	11
5.1. Tabel Perbandingan Performa	11
5.2. Analisis Perbandingan Model	11
5.3. Confusion Matrix	11
5.4. Grafik Perbandingan Performa.....	12

BAB VI PEMBAHASAN	13
6.1. SVM Sebagai Model Terbaik.....	13
6.2. Trade-off Akurasi, Kompleksitas, Dan Interpretabilitas	13
6.3. Implikasi Bagi Institusi Pendidikan	14
BAB VII DESAIN APLIKASI	15
7.1. Arsitektur Aplikasi	15
7.2. Alur UI/UX	15
7.3. Penyimpanan Model.....	15
BAB VIII KESIMPULAN	16
8.1. Capaian Outcome	16
8.2. Keterbatasan	16
8.3. Rekomendasi	17
DAFTAR PUSTAKA	18

BAB I

PENDAHULUAN & STUDI LITERATUR

1.1. Latar Belakang

Prediksi kelulusan mahasiswa merupakan salah satu persoalan penting dalam ranah *Educational Data Mining* (EDM) dan *Learning Analytics* karena berkaitan langsung dengan kualitas tata kelola akademik, efektivitas layanan pembelajaran, serta keberlanjutan studi mahasiswa. Perguruan tinggi tidak hanya dituntut menghasilkan lulusan, tetapi juga perlu memastikan bahwa proses akademik berlangsung tepat waktu, adil, terukur, dan responsif terhadap risiko keterlambatan atau kegagalan studi.

Dalam konteks ini, keterlambatan kelulusan dan *dropout* bukan sekadar indikator administratif, melainkan gejala akademik yang dapat dipengaruhi oleh banyak faktor, seperti capaian nilai semester awal, jumlah mata kuliah yang disetujui atau tidak dievaluasi, status pembayaran, beasiswa, usia saat masuk, latar belakang pendidikan sebelumnya, serta karakteristik sosial-ekonomi. Masalah utama yang dibingkai dalam penelitian ini adalah bagaimana membangun model klasifikasi yang mampu memprediksi status kelulusan mahasiswa secara lebih akurat dan dapat dipertanggungjawabkan.

Dataset yang digunakan adalah UCI *Predict Students' Dropout and Academic Success*, yang berisi 4.424 baris dan 35 fitur prediktor. Dalam tahap pemodelan biner, target difokuskan pada dua kelas: mahasiswa yang berhasil lulus (*Graduate*) dan mahasiswa yang tidak lulus tepat waktu atau berstatus risiko kegagalan studi (*Dropout*). Data olahan yang siap untuk eksperimen biner berjumlah 3,630 baris dengan 37 kolom, tanpa nilai hilang dan tanpa baris duplikat. Distribusi target menunjukkan ketidakseimbangan kelas dengan rasio sekitar 1.55.

1.2. Tujuan Proyek

Proyek ini bertujuan untuk:

- Membangun dan membandingkan model klasifikasi (KNN, Naive Bayes, SVM) untuk prediksi kelulusan mahasiswa.
- Mengoptimasi hiperparameter menggunakan GridSearchCV dengan *Stratified K-Fold Cross-Validation*.
- Menerapkan seleksi fitur berbasis *Mutual Information* untuk mengidentifikasi fitur paling informatif.
- Menangani ketidakseimbangan kelas menggunakan SMOTE dan *class weight*.
- Mengevaluasi model menggunakan metrik *F1-Score Macro*, akurasi, presisi, *recall*, dan *balanced accuracy*.

1.3 Relevansi Dengan Outcome-Based Education (OBE)

Proyek ini sejalan dengan prinsip *Outcome-Based Education* (OBE) karena mengukur capaian pembelajaran melalui outcome yang terukur: kemampuan mahasiswa dalam merancang, mengimplementasikan, dan mengevaluasi model machine learning untuk kasus nyata. Hasil berupa model teroptimasi, laporan analisis, dan prototipe aplikasi merupakan bukti konkret pencapaian kompetensi mata kuliah Machine Learning.

1.4 Kajian Pustaka Prediksi Kelulusan Mahasiswa

Literatur mutakhir menunjukkan bahwa prediksi kelulusan mahasiswa semakin banyak dikembangkan melalui klasifikasi terawasi, seleksi fitur, penanganan ketidakseimbangan kelas, *ensemble learning*, serta pendekatan interpretabilitas dan *fairness*. Kajian pustaka dilakukan terhadap 10 artikel ilmiah dari jurnal terindeks Scopus (minimal Q3) atau SINTA 2, yang dipublikasikan pada tahun 2024–2026.

1.5 Sesintesis Temuan Dan Metode Optimasi

Dari kajian literatur tersebut, teridentifikasi beberapa temuan kunci yang menjadi dasar desain eksperimen proyek ini:

- **Seleksi fitur meningkatkan performa:** Setiadi dkk. (2024) menunjukkan bahwa kombinasi algoritma klasifikasi (KNN, SVM, Naive Bayes) dengan seleksi fitur optimal menghasilkan prediksi kelulusan tepat waktu yang lebih akurat (doi: 10.18280/isi.290412).
- **Penanganan ketidakseimbangan kelas krusial:** Hermanto dkk. (2024), Jain dkk. (2025), dan Althaqafi dkk. (2025) menegaskan bahwa SMOTE dan teknik *class imbalance handling* meningkatkan F1-score dan AUC secara signifikan pada dataset pendidikan yang tidak seimbang.
- **Ensemble meningkatkan robustness:** Okoye dkk. (2024) mengembangkan model RG-DMML berbasis ensemble yang mengungguli model individual dalam prediksi retensi dan kelulusan (doi: 10.1016/j.caeai.2024.100205).
- **SVM, KNN, dan Naive Bayes dominan:** Pelima dkk. (2024) dalam *systematic literature review* di IEEE Access mengonfirmasi bahwa SVM, KNN, dan *ensemble classifiers* merupakan algoritma paling banyak digunakan untuk prediksi kelulusan (doi: 10.1109/access.2024.3361479).
- **Fairness dan transparansi:** Raftopoulos dkk. (2024) menekankan bahwa model prediksi pendidikan harus adil dan transparan karena output-nya berpotensi memengaruhi perlakuan akademik terhadap mahasiswa (doi: 10.3390/a17120572).

BAB II

DATASET DAN DATA DICTIONARY

2.1. Sumber Dataset

Dataset yang digunakan dalam penelitian ini bersumber dari UCI Machine Learning Repository dengan judul *Predict Students' Dropout and Academic Success*. Dataset ini dipublikasikan oleh Realinho dkk. (2022) dan tersedia secara terbuka di bawah lisensi Creative Commons Attribution

4.0 International (CC BY 4.0) dengan DOI: 10.24432/C5MC89.

Parameter	Keterangan
Sumber	UCI Machine Learning Repository
DOI	10.24432/C5MC89
Lisensi	CC BY 4.0
Jumlah Sampel (total)	4.424 mahasiswa
Jumlah Sampel (digunakan)	3,630 mahasiswa (biner: Graduate vs Dropout)
Jumlah Fitur	37 kolom (35 fitur + 1 target + 1 biner)
Target	Graduate (1) vs Dropout (0)
Distribusi Target	Graduate: 2,209 Dropout: 1,421
Rasio Imbalance	1.55

2.2. Fitur Yang Digunakan (Top 8 Berdasarkan Mutual Information)

Seleksi fitur dilakukan menggunakan *Mutual Information* untuk mengidentifikasi 8 fitur paling informatif terhadap target kelulusan. Fitur-fitur terpilih mencerminkan indikator akademik semester awal, finansial, dan demografis:

No.	Fitur	Tipe	Deskripsi
1	Curricular_units_2nd_sem_approved	integer	Jumlah SKS semester 2 yang lulus
2	Curricular_units_1st_sem_approved	integer	Jumlah SKS semester 1 yang lulus
3	Curricular_units_2nd_sem_grade	float	Rata-rata nilai semester 2
4	Curricular_units_1st_sem_grade	float	Rata-rata nilai semester 1
5	Tuition_fees_up_to_date	binary	Status pembayaran SPP
6	Scholarship_holder	binary	Status penerima beasiswa
7	Age_at_enrollment	integer	Usia saat pendaftaran
8	Admission_grade	float	Nilai masuk

2.3. Etika Pengguna Data

Dataset UCI telah dianonimkan oleh penyedia data dan tidak mengandung identitas langsung mahasiswa (nama, NIM, alamat). Seluruh data diproses secara lokal dan tidak dibagikan ke pihak ketiga. Hasil prediksi digunakan semata-mata untuk tujuan akademik dan tidak dimaksudkan sebagai keputusan tunggal terhadap status mahasiswa. Model berfungsi sebagai sistem pendukung keputusan yang memerlukan verifikasi dan pertimbangan manusia.

BAB III

AUDIT DATA DAN PREPROCESSING

3.1. Hasil Audit Dataset

Audit awal dataset dilakukan untuk memastikan kualitas data sebelum proses pemodelan. Hasil audit menunjukkan kondisi dataset yang relatif bersih:

Aspek	Hasil	Tindakan
Missing Values	0 nilai hilang	Tidak diperlukan imputasi
Duplikat	0 baris duplikat	Tidak diperlukan deduplikasi
Outlier	27 kolom dengan outlier terdeteksi	Ditangani oleh scaling (StandardScaler)
Imbalance	Rasio 1.55 (Graduate:2,209 vs Dropout:1,421)	Ditangani oleh SMOTE dan class_weight

3.2. Encoding Dan Scaling

Seluruh fitur yang digunakan bersifat numerik (integer atau float), sehingga tidak diperlukan *encoding* kategorikal tambahan. Fitur biner (*Tuition_fees_up_to_date*, *Scholarship_holder*) sudah dalam format 0/1. Proses *scaling* menggunakan *StandardScaler* dari scikit-learn untuk menormalisasi fitur ke distribusi dengan mean=0 dan standar deviasi=1. *Scaling* ini penting terutama untuk SVM dan KNN yang sensitif terhadap skala fitur.

3.3. Encoding Dan Scaling

Dataset menunjukkan ketidakseimbangan kelas dengan rasio 1.55, di mana kelas *Graduate* (2,209) lebih dominan dibanding kelas *Dropout* (1,421). Penanganan dilakukan dengan dua strategi:

- **SMOTE (Synthetic Minority Oversampling Technique):** Menghasilkan sampel sintetis pada kelas minoritas (*Dropout*) agar proporsi kelas lebih seimbang pada data latih. SMOTE hanya diterapkan pada data latih untuk mencegah kebocoran data.
- **Class Weight:** Pada model SVM dan Naive Bayes, parameter *class_weight='balanced'* memberikan penalti lebih besar pada kesalahan prediksi kelas minoritas.

3.4. Leakage Awareness

Untuk mencegah kebocoran data (*data leakage*), proses *scaling* dan SMOTE hanya dilakukan pada data latih. Objek *scaler* di-fit pada data latih, kemudian digunakan untuk mentransformasi data latih dan data uji secara terpisah. Tidak ada informasi dari data uji yang digunakan dalam proses preprocessing. Pembagian data dilakukan sebelum proses *scaling* dan SMOTE menggunakan *stratified split*.

BAB IV

DESAIN EKSPERIMEN

4.1. Pembagian Data

Pembagian data latih-uji menggunakan rasio 80:20 dengan stratifikasi berdasarkan variabel target. *Stratified split* memastikan proporsi kelas *Graduate* dan *Dropout* konsisten pada data latih dan data uji. Parameter *random_state=42* digunakan untuk reproducibility.

4.2. Algoritma Klasifikasi

- K-Nearest Neighbors (KNN):** Algoritma berbasis jarak yang mengklasifikasikan berdasarkan mayoritas tetangga terdekat.
- Naive Bayes:** Algoritma probabilistik berdasarkan teorema Bayes dengan asumsi independensi antara fitur.
- Support Vector Machine (SVM):** Algoritma yang mencari hiperpemisah optimal dengan margin maksimum antara kelas.

4.3. Parameter Baseline

Model	Parameter Baseline
KNN	n_neighbors=5, metric='minkowski', p=2
Naive Bayes	default (GaussianNB)
SVM	kernel='rbf', C=1.0, gamma='scale'

4.4. Hyperparameter Grid Untuk Optimasi

Model	Parameter	Nilai Grid
KNN	n_neighbors	[3, 5, 7, 9, 11]
KNN	weights	['uniform', 'distance']
KNN	metric	['euclidean', 'manhattan']
Naive Bayes	var_smoothing	[1e-9, 1e-8, 1e-7, 1e-6]
SVM	C	[0.1, 1, 10, 100]
SVM	gamma	['scale', 'auto', 0.01, 0.001]
SVM	kernel	['rbf', 'linear']

4.5. Validasi Silang Dan Metrik Evaluasi

Validasi silang menggunakan *Stratified K-Fold Cross-Validation* dengan $K=5$. Setiap lipatan mempertahankan proporsi kelas target. Metrik utama yang dioptimalkan adalah **F1-Score Macro**, yang memperhitungkan rata-rata harmonik presisi dan recall untuk kedua kelas secara setara, sehingga tidak bias terhadap kelas mayoritas. Metrik tambahan meliputi *Accuracy*, *Precision Macro*, *Recall Macro*, dan *Balanced Accuracy*.

BAB V

HASIL EKSPERIMEN

5.1. Tabel Perbandingan Performa

Model	Accuracy	Precision	Recall	F1-Score	Bal. Acc.
KNN (Baseline)	0.8788	0.8836	0.8608	0.8693	0.8608
Naive Bayes (Baseline)	0.8444	0.8532	0.8187	0.8294	0.8187
SVM (Baseline)	0.8939	0.8945	0.8814	0.8869	0.8814
KNN (Optimized)	0.8843	0.8857	0.8697	0.8762	0.8697
Naive Bayes (Optimized)	0.8526	0.8661	0.8255	0.8376	0.8255
SVM (Optimized)	0.8912	0.8909	0.8792	0.8841	0.8792

5.2. Analisis Perbandingan Model

Hasil eksperimen menunjukkan bahwa SVM Baseline mencapai performa tertinggi pada metrik utama F1-Score Macro sebesar **0.8869**, dengan akurasi **0.8939**, presisi makro **0.8945**, dan recall makro **0.8814**. SVM menunjukkan konsistensi yang baik antara baseline dan optimasi (F1: 0.8869 vs 0.8841), mengindikasikan bahwa konfigurasi default SVM sudah mendekati optimal untuk dataset ini.


KNN menunjukkan peningkatan setelah optimasi (F1: 0.8693 → 0.8762), sementara Naive Bayes juga mengalami perbaikan moderat (F1: 0.8294 → 0.8376). Secara keseluruhan, SVM unggul diikuti KNN dan Naive Bayes.

5.3. Confusion Matrix

		Prediksi	
		Dropout	Graduate
Aktual	Dropout	234	50
	Graduate	27	415

Confusion matrix menunjukkan bahwa SVM Baseline berhasil mengklasifikasikan 234 mahasiswa *Dropout* dengan benar (True Negative) dan 415 mahasiswa *Graduate* dengan benar (True Positive). Terdapat 50 False Positive (mahasiswa *Dropout* diprediksi *Graduate*) dan 27 False Negative (mahasiswa *Graduate* diprediksi *Dropout*).

5.4. Grafik Perbandingan Performa



BAB VI

PEMBAHASAN

6.1. SVM Sebagai Model Terbaik

Support Vector Machine (SVM) terpilih sebagai model terbaik berdasarkan F1-Score Macro sebesar 0.8869. Keunggulan SVM dapat dijelaskan dari perspektif akademis sebagai berikut:

- **Margin maksimum:** SVM mencari hiperpemisah yang memaksimalkan margin antara kelas *Graduate* dan *Dropout*. Properti ini menghasilkan generalisasi yang lebih baik, terutama pada data dengan dimensi tinggi.
- **Kernel RBF:** Kernel *Radial Basis Function* memungkinkan SVM menangkap hubungan non-linear antara fitur akademik dan status kelulusan, yang relevan karena pola kelulusan mahasiswa tidak selalu linier.
- **Robustness terhadap fitur tidak relevan:** SVM cenderung lebih tahan terhadap fitur yang kurang informatif karena hanya titik data di dekat margin (*support vectors*) yang memengaruhi model.
- **Konsistensi performa:** Selisih F1-Score antara baseline (0.8869) dan optimasi (0.8841) sangat kecil, menunjukkan bahwa SVM stabil dan tidak terlalu sensitif terhadap perubahan hiperparameter pada dataset ini.

6.2. Trade-off Akurasi, Kompleksitas, Dan Interpretabilitas

Aspek	SVM	KNN	Naive Bayes
F1-Score	0.8869 (tertinggi)	0.8693	0.8294
Akurasi	0.8939	0.8788	0.8444
Waktu Latih	0.48 detik	0.007 detik	0.001 detik
Interpretabilitas	Rendah (kernel trick)	Sedang (jarak)	Tinggi (probabilistik)
Kompleksitas	$O(n^2 \sim n^3)$	$O(n \cdot d)$	$O(n \cdot d)$

SVM menawarkan akurasi tertinggi dengan waktu latih yang moderat (0.48 detik). KNN lebih cepat namun kurang akurat, sementara Naive Bayes paling cepat dan mudah diinterpretasi tetapi dengan akurasi terendah. Dalam konteks prediksi kelulusan, akurasi dan kemampuan mengenali kelas minoritas (*Dropout*) lebih diutamakan daripada interpretabilitas penuh, sehingga SVM merupakan pilihan optimal.

6.3. Implikasi Bagi Institusi Pendidikan

Hasil penelitian ini memiliki beberapa implikasi praktis bagi institusi pendidikan tinggi:

- **Identifikasi dini mahasiswa berisiko:** Model dapat digunakan sebagai alat bantu untuk mendeteksi mahasiswa dengan risiko *dropout* berdasarkan pola akademik semester awal.
- **Prioritas intervensi akademik:** Mahasiswa yang diprediksi berisiko dapat diprioritaskan untuk konseling akademik, bimbingan belajar, atau bantuan administratif.
- **Pengambilan keputusan berbasis data:** Pihak program studi dan dekanat dapat menggunakan hasil prediksi sebagai salah satu pertimbangan dalam pengambilan kebijakan akademik.
- **Evaluasi kebijakan:** Fitur-fitur paling informatif (SKS lulus, nilai semester, pembayaran SPP) dapat menjadi fokus evaluasi efektivitas kebijakan akademik.

BAB VII

DESAIN APLIKASI

7.1. Arsitektur Aplikasi

Aplikasi prediksi kelulusan dikembangkan sebagai prototipe berbasis *web* menggunakan framework Streamlit/Flask. Arsitektur aplikasi terdiri dari:

- **Frontend:** Antarmuka web responsif yang memungkinkan pengguna memasukkan nilai fitur mahasiswa (SKS lulus, nilai semester, status pembayaran, dll.) dan melihat hasil prediksi.
- **Backend:** Server Python yang memuat model SVM teroptimasi (*best_student_graduation_model.joblib*) dan scaler (*scaler.joblib*) untuk memproses input dan menghasilkan prediksi.
- **Model Pipeline:** Input pengguna → *scaling* (StandardScaler) → prediksi SVM → output probabilitas dan kelas (Graduate/Dropout).

7.2. Alur UI/UX

Alur penggunaan aplikasi dirancang sederhana dan intuitif:

1. Pengguna membuka halaman utama aplikasi.
2. Pengguna mengisi formulir input dengan 8 fitur yang diperlukan.
3. Sistem memvalidasi input dan melakukan preprocessing (scaling).
4. Model SVM menghasilkan prediksi beserta tingkat kepercayaan.
5. Hasil ditampilkan dalam bentuk kelas prediksi (Graduate/Dropout) dan probabilitas.
6. Pengguna dapat melihat penjelasan singkat tentang kontribusi fitur terhadap prediksi.

7.3. Penyimpanan Model

Model SVM teroptimasi disimpan dalam format *joblib* untuk efisiensi serialisasi. File yang disimpan meliputi:

- *models/best_student_graduation_model.joblib*: Model SVM teroptimasi.
- *models/scaler.joblib*: Objek StandardScaler yang telah di-fit pada data latih.

BAB VIII

KESIMPULAN

8.1. Capaian Outcome

Berdasarkan eksperimen yang telah dilakukan, dapat disimpulkan beberapa capaian utama:

- SVM Baseline terbukti menjadi model terbaik dengan F1-Score Macro **0.8869** dan akurasi **0,8939** dalam mengklasifikasikan kelulusan mahasiswa.
- Seleksi fitur menggunakan *Mutual Information* berhasil mengidentifikasi 8 fitur paling informatif, dengan fitur akademik semester (SKS lulus dan nilai) sebagai prediktor terkuat.
- Penanganan ketidakseimbangan kelas melalui SMOTE dan *class weight* berkontribusi pada peningkatan recall kelas minoritas (*Dropout*).
- Optimasi hiperparameter menggunakan GridSearchCV dengan *Stratified 5-Fold CV* menghasilkan peningkatan pada KNN (F1: 0.8693 → 0.8762) dan Naive Bayes (F1: 0.8294 → 0.8376).
- Prototipe aplikasi prediksi berhasil dikembangkan dengan pipeline end-to-end dari input pengguna hingga output prediksi.

8.2. Keterbatasan

- Dataset berasal dari satu institusi pendidikan tinggi di Portugal, sehingga generalisasi ke konteks Indonesia perlu diuji lebih lanjut.
- Model hanya mengklasifikasikan dua kelas (Graduate vs Dropout) dan tidak mencakup mahasiswa yang masih berstatus *Enrolled*.
- Interpretabilitas SVM terbatas karena penggunaan kernel non-linear (*RBF*), sehingga penjelasan kontribusi fitur memerlukan teknik tambahan seperti SHAP atau LIME.
- Fitur-fitur yang digunakan bersifat akademik dan administratif, belum mencakup faktor psikososial, motivasi, atau dukungan keluarga.
- Eksperimen belum menguji model ensemble (Random Forest, Gradient Boosting) yang berpotensi mengungguli model individual.

8.3. Rekomendasi

- Pengujian model pada dataset institusi Indonesia untuk menguji daya generalisasi.
- Pengembangan model multi-kelas (Graduate, Dropout, Enrolled) untuk cakupan prediksi yang lebih luas.
- Integrasi teknik interpretabilitas (SHAP, LIME) untuk meningkatkan transparansi model.
- Pengujian model ensemble (Random Forest, XGBoost, LightGBM) sebagai baseline tambahan.
- Pengumpulan fitur tambahan seperti data kehadiran, aktivitas LMS, dan survei motivasi untuk meningkatkan akurasi prediksi.
- Pengembangan sistem *early warning* terintegrasi yang menggabungkan prediksi model dengan mekanisme konseling akademik.

DAFTAR PUSTAKA

- [1] Haryono Setiadi, Krisna Sanjaya, Ardhi Wijayanto, Dewi Wisnu Wardhani, Hasan Dwi Cahyono (2024). "Comparative Analysis of Classification Algorithms Using Feature Selection Techniques to Predict On-Time Student Graduation." *Ingénierie des systèmes d'information*. <https://doi.org/10.18280/isi.290412>
- [2] Dedy Hermanto, Desy Iba Ricoida, Desi Pibriana, Rusbandi Rusbandi, Muhammad Rizky Pribadi (2024). "Analysis of Student Graduation Prediction Using Machine Learning Techniques on an Imbalanced Dataset: An Approach to Address Class Imbalance." *Scientific Journal of Informatics*. <https://doi.org/10.15294/sji.v1i13.5528>
- [3] Lidya R. Pelima, Yuda Sukmana, Yusep Rosmansyah (2024). "Predicting University Student Graduation Using Academic Performance and Machine Learning: A Systematic Literature Review." *IEEE Access*. <https://doi.org/10.1109/access.2024.3361479>
- [4] Kingsley Okoye, Julius T. Nganji, José Escamilla, Samira Hosseini (2024). "Machine learning model (RG-DMML) and ensemble algorithm for prediction of students' retention and graduation in education." *Computers and Education Artificial Intelligence*. <https://doi.org/10.1016/j.caeai.2024.100205>
- [5] Achin Jain, Arun Kumar Dubey, Shakir Khan, Arvind Panwar, Mohammad Alkhatib, Abdulaziz M Alshahrani (2025). "A PSO weighted ensemble framework with SMOTE balancing for student dropout prediction in smart education systems." *Scientific Reports*. <https://doi.org/10.1038/s41598-025-97506-1>
- [6] Turki Althaqafi, Farrukh Saleem, Abdullah Alghamdi (2025). "Enhancing student performance prediction: the role of class imbalance handling in machine learning models." *Discover Computing*. <https://doi.org/10.1007/s10791-025-09576-4>
- [7] Diego Monteverde-Suárez, Patricia González-Flores, Roberto Santos Solórzano, Manuel García-Minjares, Irma Rocío Zavala-Sierra, Verónica Luna de la Luz, Melchor Sánchez Mendiola (2024). "Predicting students' academic progress and related attributes in first-year medical students: an analysis with artificial neural networks and Naïve Bayes." *BMC Medical Education*. <https://doi.org/10.1186/s12909-023-04918-6>
- [8] George Raftopoulos, Gregory Davrazos, Sotiris Kotsiantis (2024). "Fair and Transparent Student Admission Prediction Using Machine Learning Models." *Algorithms*. <https://doi.org/10.3390/a17120572>
- [9] Radiah Haque, Albert Quek, Choo-Yee Ting, Hui-Ngo Goh, Md. Rakibul Hasan (2024). "Classification Techniques Using Machine Learning for Graduate Student Employability Predictions." *International Journal on Advanced Science Engineering and Information Technology*. <https://doi.org/10.18517/ijaseit.14.1.19549>
- [10] Agus Santoso, Heri Retnawati, Kartianom Kartianom, Ezi Apino, Ibnu Rafi, Munaya Nikma Rosyada (2024). "Predicting Time to Graduation of Open University Students: An Educational Data Mining Study." *Open Education Studies*. <https://doi.org/10.1515/edu-2022-0220>
- [11] Realinho, V., Machado, J., Baptista, L., & Martins, M.V. (2022). "Predicting Student Dropout and Academic Success." *UCI Machine Learning Repository*. doi: 10.24432/C5MC89